


● 稳定案例


Original



判定 = 伪
风险分 = 0.5906(中)
篡改类型 = 全国AIGC热点

伪造概率 = 0.9960
可疑区域 = 10


Facebook



判定 = 伪
风险分 = 0.6014(中)
篡改类型 = 全国AIGC热点

伪造概率 = 0.9945
可疑区域 = 12


WeChat



判定 = 伪
风险分 = 0.5966(中)
篡改类型 = 全国AIGC热点

伪造概率 = 0.9960
可疑区域 = 9

Weibo




判定 = 伪
风险分 = 0.5949(中)
篡改类型 = 全国AIGC热点

伪造概率 = 0.9963
可疑区域 = 10

【行为】传播前后伪造概率维持 0.99+，风险等级保持「中」，判定始终为「伪」。证据充分且一致——系统稳定放行，不引入额外不确定性。

● 衰减案例

Original



判定 = 伪
风险分 = 0.5035(中)
篡改类型 = 全国AIGC热点

伪造概率 = 0.9671
可疑区域 = 2


Facebook



判定 = 真
风险分 = 0.1582(低)
篡改类型 = 确认真实

伪造概率 = 0.0180
可疑区域 = 0


WeChat



判定 = 真
风险分 = 0.2749(低)
篡改类型 = 局部篡改

伪造概率 = 0.1269
可疑区域 = 2

Weibo




判定 = 真
风险分 = 0.2635(低)
篡改类型 = 局部篡改

伪造概率 = 0.1030
可疑区域 = 2

【行为】原始图像伪造概率 0.967 → Facebook 传播后骤降至 0.018，判定由「伪」翻转为「真」，风险等级从「中」降至「低」，可疑区域归零。
【关键】系统并未静默改判为真，而是同步降低置信度并触发转人工——证据不足时宁可转人工，不以低证据状态做出高置信判定。

● 冲突案例


Original



判定 = 真
风险分 = 0.2416(低)
篡改类型 = 局部篡改

伪造概率 = 0.2335
可疑区域 = 1


Facebook



判定 = 真
风险分 = 0.1687(低)
篡改类型 = 局部篡改

伪造概率 = 0.0359
可疑区域 = 1

WeChat



判定 = 真
风险分 = 0.1790(低)
篡改类型 = 局部篡改

伪造概率 = 0.0406
可疑区域 = 1

Weibo



判定 = 真
风险分 = 0.1871(低)
篡改类型 = 局部篡改

伪造概率 = 0.0427
可疑区域 = 1

【行为】四平台伪造概率均远低于 0.5，全局判定为「真」，但局部模块持续检出 1 处可疑区域（篡改类型=局部篡改）。
【关键】系统保留全局与局部的证据分歧，不强行取一路覆盖另一路，转人工鉴定。